### Mini Project 01 - IMDB web scraping

```
print(url)
[1] "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating,desc"

#read html
imdb <- read_html(url)</pre>
```

url <- "https://www.imdb.com/search/title/?groups=top\_100&sort=user\_rating,desc"</pre>

# imdb {html\_document} <html xmlns:og="http://ogp.me/ns#" xmlns:fb="http://www.facebook.com/2008/fbml"</pre> [1] <head>\n<meta http-equiv="Content-Type" content="text/html; charset=UTF-8. [2] <body id="styleguide-v2" class="fixed">\n <img height="1" widt .</pre> #movie title titles <- imdb %>% html\_nodes("h3.lister-item-header") %>% #node 1 node , nodes - take a html\_text2() #text 2 delete special character titles [1:10] '1. The Shawshank Redemption (1994)' · '2. The Godfather (1972)' · '3. The Dark Knight (2008)' · '4. The Lord of the Rings: The Return of the King (2003)' · '5. Schindler\'s List (1993)' · '6. The Godfather Part II (1974)' · '7. 12 Angry Men (1957)' · '8. Pulp Fiction (1994)' · '9. Inception (2010)' · '10. The Lord of the Rings: The Two Towers (2002)' ratings <- imdb %>% html\_nodes("div.ratings-imdb-rating") %>% html\_text2() %>% as.numeric() ratings[1:10] $9.3 \cdot 9.2 \cdot 9 \cdot 9 \cdot 9 \cdot 9 \cdot 8.9 \cdot 8.8 \cdot 8.8$ num\_votes <- imdb %>%

html\_nodes("p.sort-num\_votes-visible") %>%

html\_text2()

```
#build a data set

df <- data.frame (
    title= titles,
    rating = ratings,
    num_vote = num_votes
)
head(df)</pre>
```

#### A data.frame: $6 \times 3$

	title	rating	num_vote
	<chr></chr>	<dbl></dbl>	<chr></chr>
1	1. The Shawshank Redemption (1994)	9.3	Votes: 2,671,623   Gross: \$28.34M   Top 250: #1
2	2. The Godfather (1972)	9.2	Votes: 1,851,565   Gross: \$134.97M   Top 250: #2
3	3. The Dark Knight (2008)	9.0	Votes: 2,644,435   Gross: \$534.86M   Top 250: #3
4	4. The Lord of the Rings: The Return of the King (2003)	9.0	Votes: 1,841,220   Gross: \$377.85M   Top 250: #7
5	5. Schindler's List (1993)	9.0	Votes: 1,352,467   Gross: \$96.90M   Top 250: #6
6	6. The Godfather Part II (1974)	9.0	Votes: 1,267,830   Gross: \$57.30M   Top 250: #4

## **Mini Project 02 - Spec Phone Database**

```
— Conflicts

X dplyr::filter() masks stats::filter()

X purrr::flatten() masks jsonlite::flatten()

X dplyr::lag() masks stats::lag()

Attaching package: 'rvest'
```

```
url <- read_html("https://specphone.com/Samsung-Galaxy-A04.html")</pre>
```

```
att <- url %>%
   html_nodes("div.topic") %>%
   html_text2()

value <- url %>%
   html_nodes("div.detail") %>%
   html_text2()
```

```
data.frame(attribure = att, value = value)
```

A data.frame: 31 × 2

A data.frame: 31 × 2				
attribure	value			
<chr></chr>	<chr></chr>			
วันเปิดตัว	ตุลาคม 2565			
วันวางจำหน่าย	ยังไม่วางจำหน่าย			
ขนาด	164.40 x 76.30 x 9.10 มม.			
น้ำหนัก	192 กรัม			
วัสดุ	Glass front, plastic back, plastic frame			
SIM	รองรับ 2 ซิมการ์ด (nano sim, nano sim)			
Technology	HSPA 42.2/5.76 Mbps, LTE-A			
2G	850/900/1800/1900			
3G	850/900/1900/2100			
4G	850/900/1900/2100/2600			
5G	-			
ความเร็ว	HSPA 42.2/5.76 Mbps, LTE-A			
ประเภท	PLS LCD			
ขนาดหน้าจอ	6.50 นิ้ว			
ความละเอียด	720 x 1600 pixels			
ระบบปฏิบัติการ	Android 12			
ชิปประมวลผล	Spreadtrum Unisoc SC9863A 1.6 GHz			
ชิปกราฟิก	PowerVR GE8322			
หน่วยความจำ	3 GB			
ความจุ	32 GB			
Memory Card	microSD (1)			
กล้องหลัก	ตัวที่ 1: 50 MP, f/1.8, (wide), AF ตัวที่ 2: 2 MP, f/2.4, (depth)			
ความละเอียดวีดีโอ	1080p@30fps			
กล้องหน้า	ตัวที่ 1: 5 MP, f/2.2			
Bluetooth	5.0, A2DP, LE			
Wi-Fi	802.11 a/b/g/n/ac, dual-b			
USB	Type-C			
GPS	GLONASS, GALILEO, BDS			
NFC	ไม่รองรับ			
ความจุ	5,000 mAh			
ประเภท	Non-removable Li-Po Batt			

```
# all samsung smartphones
samsung_url <- read_html("https://specphone.com/brand/Samsung")</pre>
```

```
#link to all samsung phone
links <- samsung_url %>%
  html_nodes("li.mobile-brand-item a") %>%  #a is the child in li
  html_attr("href")
```

#### links

```
'/Samsung-Galaxy-M13.html' · '/Samsung-Galaxy-A23.html' · '/Samsung-Galaxy-A13.html' ·
'/Samsung-Galaxy-M32-5G.html' · '/Samsung-Galaxy-A12-Nacho.html' · '/Samsung-Galaxy-Pocket-Neo.html'
'/Samsung-Galaxy-Young.html' · '/Samsung-Galaxy-J1-Mini.html' · '/Samsung-Galaxy-A01-Core-1-16GB.html' ·
'/Samsung-Galaxy-V-PLUS.html' · '/Samsung-Galaxy-Young-2.html' · '/Samsung-Galaxy-M02.html' ·
'/Samsung-Galaxy-A11.html' · '/Samsung-Galaxy-J2-Pro-2018.html' · '/Samsung-Galaxy-A12-2021.html' ·
'/Samsung-Galaxy-A21s-3-32GB.html' · '/Samsung-Galaxy-J5.html' · '/Samsung-Galaxy-J4.html' ·
'/Samsung-Galaxy-Core-2-Duos.html' · '/Samsung-Galaxy-Ace-Plus.html' · '/Samsung-Galaxy-A20.html' ·
'/Samsung-Galaxy-Chat.html' · '/Samsung-Galaxy-Gio.html' · '/Samsung-Galaxy-Tab-A7-Lite-LTE.html' ·
'/Samsung-Galaxy-Tab-A-10.5WIFI.html' · '/Samsung-Galaxy-Alpha.html' · '/Samsung-Galaxy-S3-Slim.html' ·
'/Samsung-Galaxy-S4-zoom.html' · '/Samsung-Galaxy-Xcover-2.html' · '/Samsung-Galaxy-Tab-8.9-3G-16GB.html' ·
'/Samsung-Galaxy-Tab-A8-LTE-2021.html' · '/Samsung-Galaxy-A8-2018.html' ·
'/Samsung-Galaxy-Tab4-8.0-wifi.html' · '/Samsung-Galaxy-M33-5G.html' · '/Samsung-Galaxy-A50.html' ·
'/Samsung-Galaxy-E7.html' · '/Samsung-Galaxy-S6.html' · '/Samsung-Galaxy-S20-FE.html' ·
'/Samsung-Galaxy-Tab-S4-WIFI.html' · '/Samsung-Galaxy-S7.html' · '/Samsung-Galaxy-Note-5-Exynos.html' ·
'/Samsung-Galaxy-TabPRO-12.2-LTE.html' · '/Samsung-Galaxy-S4-Active.html' ·
'/Samsung-Galaxy-Tab-Active-3.html' · '/Samsung-Galaxy-Tab-S3-9.7.html' · '/Samsung-Galaxy-S6-edge.html' ·
'/Samsung-Galaxy-Note-4-Exynos.html' · '/Samsung-Galaxy-Round.html' ·
'/Samsung-Galaxy-Note-20-Ultra-5G.html' · '/Samsung-ATIV-Q.html' · '/Samsung-ATIV-Smart-PC-PRO.html' ·
'/Samsung-Galaxy-S22-Ultra12-128GB.html' · '/Samsung-Galaxy-Z-Flip-5G.html' · '/Samsung-Galaxy-Z-Flip.html' ·
'/Samsung-Galaxy-Tab-S8-Ultra-5G.html' · '/Samsung-Galaxy-S21-Ultra-16-512GB.html' ·
'/Samsung-Galaxy-S10-Plus-Ram-12GB.html' · '/Samsung-Galaxy-Z-Fold-3.html' · '/Samsung-Galaxy-Z-Fold4.html' ·
'/Samsung-Galaxy-Z-Fold-2-5G.html'
```

full\_links <- paste0("https://specphone.com" ,links)</pre>

```
result <- data.frame ()</pre>
for (link in full_links[1:5]) {
    ss_topic <- link %>%
        read_html() %>%
        html_nodes("div.topic") %>%
        html_text2()
    ss_detail <- link %>%
        read_html() %>%
        html_nodes("div.detail") %>%
        html_text2()
    tmp <- data.frame(attrbute = ss_topic ,</pre>
                      value= ss_detail)
    result <- bind_rows (result, tmp)</pre>
    print ("Profress...")
}
print (result)
[1] "Profress..."
[1] "Profress..."
[1] "Profress..."
[1] "Profress..."
[1] "Profress..."
           attrbute
1
            วันเปิดตัว
2
       วันวางจำหน่าย
3
               ขนาด
              น้ำหนัก
4
5
                วัสด
                SIM
6
7
        Technology
8
                 2G
9
                 3G
10
                 4G
11
                 5G
12
            ความเร็ว
```

```
#write csv
write_csv (result, "result_ss_phone.csv")
```

13

14

ประเภท

ขบาดหบ้าจอ

### print(head(result),3)

	attrbute	value
1	วันเปิดตัว	มิถุนายน 2565
2	วันวางจำหน่าย	ยังไม่วางจำหน่าย
3	ขนาด	165.40 x 76.90 x 8.40 มม.
4	น้ำหนัก	192 กรัม
5	วัสดุ	Glass front, plastic back, plastic frame
6	SIM	รองรับ 2 ซิมการ์ด (nano sim, nano sim)